

Sistem za upravljanje korisnicima i objavama na forumu

Opis problema

Sistem za upravljanje korisnicima i objavama na forumima rešio bi problem mnogih socijalnih platformi koje u svom opisu imaju deljenje tekstualnog sadržaja. Glavni zadatak iz aspekta **objava** jeste da se uoče *trending* objave, ali i isprate one koje su potencijalno štetne za zajednicu i odreaguje pravilno. Sa druge strane, imamo **korisnike**, čije se ponašanje može ili nagraditi određenim bedževima/tokenima, ili kazniti restrikcijom aktivnosti (odnosno, suspenzijom naloga u krajnjem slučaju).

Ovakvu logiku možemo uočiti na dosta platformi. Neki od primera su:

- **Facebook** grupe sa labelama za najaktivnije članove,
- **StackOverflow** koji prati korisnike koji su najkvalitetnije doprineli zajednici kvalitetnim odgovorima,
- i **Twitter** koji prati Trending teme i tvitove.

Naše rešenje bi objedinilo gore navedene pojave, uz dodatak sankcionisanja za toksično ponašanje. Predstavljao bi visoko-fleksibilnu implementaciju koja se lako može ugraditi u bilo koji sistem kome bi opisana evaluacija korisnika i njihove aktivnosti bila od koristi.

Metodologija

Naš sistem zasniva se na događajima koji pristižu u realnom vremenu. Bitno nam je vreme svake instance jer ovako možemo da imamo u uvid učestalost i šablone korisničkog ponašanja.

Događaji koje sistem prati su sledeći:

1. Registracija novog korisnika (korisničko ime)
2. Postavljanje nove objave (sadržaj objave i vlasnik iste)
3. *Like post*
4. *Dislike post*
5. *Report post for harmful content*

Jedan od dva osnovna entiteta sistema je objava:

- Objava pored sadržaja ima podatak u vremenu kada je postavljena i korisniku koji ju je objavio
- Čuvaju se broj *lajkova*, *dislajkova*, i prijava objave
- Ukoliko je postavljena objava naglo izrazito popularnija u odnosu na ostale objave postavljene u sličnom vremenskom periodu, dobija **Trending** labelu. Ovakve objave ne smeju da imaju bilo kakvu negativnu oznaku. U sistemu je u svakom momentu samo ograničen broj objava *Trending*, i ovo se određuje srazmerno broju novopristiglih postova u određenom vremenskom periodu.

- Objava koja ima slab odnos *lajkova* i *dislajkova* dobija labelu **Poor Content**¹. U kompletnom sistemu bi ove objave trebale biti slabije prikazivane korisnicima i generalno manje promovisane.
- Objava koja je dobila veliki broj prijava labelirana je kao **Potentially Harmful**, i u tom slučaju ide na proveru. Provera može biti ručna, izvedena pomoću zasebnog API-ja, ili asistencijom neuronske mreže, međutim za obim ovog zadatka logika provere će biti apstrahovana.
- Ukoliko se proverom uspostavi da objava nije bila štetna, ona se označava kao **Poor Content**.
- Ukoliko se proverom uspostavi da objava jeste bila štetna po zajednicu (govor mržnje, spam, maliciozni linkovi etc.), dobija labelu **Harmful** i ima značajne konsekvence po korisnika autora. Idealno, u kompletnoj aplikaciji ove objave se ne prikazuju više drugim korisnicima ili se brišu iz javnog sistema.

Sledeći entitet značajan za sistem jeste korisnik:

- Svaka korisnička aktivnost se prati, i u zavisnosti od nje korisnik biva labeliran na adekvatan način. U okviru kompletnog sistema ove labele mogu pomoći i u realizaciji kompleksnijih funkcionalnosti sistema, ali i u vizualnom prenošenju važnih informacija drugim korisnicima.
- Ukoliko korisnik redovno objavljuje sadržaj koji dobija dobar odnos *lajkova* i *dislajkova* dobija labelu **Top User**. Ova labela može da se izgubi prestankom aktivnosti.
- Ukoliko korisnik redovno *lajkuje* generalno dobar sadržaj dobija labelu **Community Contributor**. Ona takođe može da se izgubi prestankom aktivnosti.
- Korisnik koji izvršava previše aktivnosti u jedinici vremena privremeno biva suspendovan i labeliran kao **Spammer**.
- Korisnik čije su objave (jedna ili više) označene kao *Harmful* dobija labelu **Harmful User**.
- Ukoliko korisnik rapidno *dislajkuje* i/ili prijavljuje objave biva labeliran kao **Potential Spammer**.
- Za *Potential Spammer*-a potrebno je izvršiti analizu prethodno urađenih akcija. Ako su su radnje opravdane, odnosno vidimo da su negativne reakcije i prijave bile na objavama koje su *Poor Content* ili *Harmful* ponašanje je opravdano i poništava se aktivna labela. Ukoliko je naizgled nasumično, korisnik dobija labelu **Spammer**.
- *Spammer* labela ističe posle određenog vremena, ali je *Harmful User* peramentna.

Poslednji pojam od značaja bile bi sankcije za korisnike:

- Korisnik koji je 5 puta dobio *Spammer* labelu je trajno suspendovan
- Korisnik koji trenutno poseduje *Spammer* labelu suspendovan je od svih aktivnosti 2 dana
- *Harmful User* koji je napravio 5 *Harmful* objava je trajno suspendovan
- *Harmful User* koji dodatno dobije labelu *Spammer* je trajno suspendovan

¹ Podrazumevana labela koja bi se nalazila između *Trending* i *Poor Content* radi lakše realizacije mogla bi biti samo **Content**.

REALIZACIJA SISTEMA

Možemo izdvojiti nekoliko grupa pravila koja su logički odvojena:

1. Pravila za labeliranje objava
2. Pravila za labeliranje korisnika
3. Pravila za primenu kazni korisnika

PRAVILA ZA LABELIRANJE OBJAVA

Objava je postavljena u prethodna 24h i
nema labelu *Poor Content* i
spada u top 10% svih objava objavljenih u prethodna 24h po broju lajkova
→ objava je označena kao *Trending*

Objava je duže od 3 dana imala labelu *Trending*
→ objava gubi labelu *Trending*

Objava ima status *Trending* i
objava ima status *Harmful* ili *Poor Content*
→ objava gubi labelu *Trending*

Objava ima odnos *like:dislike* jednak ili slabiji od 3:2
→ objava je označena kao *Poor Content*

Objava je dobila 10 ili više prijava
→ objava je labelirana kao *Potentially Harmful* i ide na analizu
(zaključno, menja se labela ili u *Harmful* ili u *Poor Content*)

PRAVILA ZA UPRAVLJANJE KORISNICIMA

Korisnik je objavio minimalno jednu objavu svaka dva dana u prethodnih mesec dana i
od gorepomenutih objava ni jedna nije *Poor Content* ili *Potentially Harmful* i
korisnik nije *Spammer* i
u prethodnih 6 meseci korisnik nije imao *Harmful* objavu
→ korisnik postaje *Top User*

Korisnik je *Top User* i
objavio je *Poor Content*, *Potentially Harmful* ili *Harmful* objavu
→ korisnik gubi status *Top User*

Korisnik je *Top User* i
korisnik ima labelu *Spammer*
→ korisnik gubi status *Top User*

Korisnik je *Top User* i
u prethodnih mesec dana nije postavio minimalno jednu objavu svaka 2 dana
→ korisnik gubi status *Top User*

Korisnik je u prethodnih mesec dana minimalno 20 puta nedeljno lajkovao objave označene kao
Content ili *Trending* i
korisnik nije *Spammer*
→ korisnik postaje *Community Contributor*

Korisnik je *Community Contributor* i
u prethodnih nedelju dana nije lajkovao minimalno 20 *Content* ili *Trending* objava
→ korisnik gubi status *Community Contributor*

Korisnik je *Community Contributor* i
korisnik je *Spammer*
→ korisnik gubi status *Community Contributor*

Korisnik je izvršio više od 45 proizvoljnih akcija u minuti
→ korisnik postaje *Spammer*

Korisnik je objavio više od 10 objava u poslednjih 5 minuta
→ korisnik postaje *Spammer*

Korisnik ima barem jednu *Harmful* objavu
→ korisnik postaje *Harmful User*

Dislike/report aktivnost je sačinjala barem $\frac{1}{2}$ svih korisnikovih radnji u protehla 24h i
korisnik je imao više od 30 aktivnosti u prethodna 24h
→ korisnik je označen kao *Potential Spammer*

Korisnik je *Potential Spammer* i
80% *dislike* aktivnosti u prethodna 24h su izvršene nad *Poor Content* ili *Harmful* objavama i
80% *report* aktivnosti u prethodna 24h su izvršene nad *Poor Content* ili *Harmful* objavama
→ korisnik gubi status *Potential Spammer*

Korisnik je *Potential Spammer* i

80% *dislike* aktivnosti u prethodna 24h su izvršene nad *Content* ili Trending objavama i

→ korisnik postaje *Spammer*

Korisnik je *Potential Spammer* i

80% *report* aktivnosti u prethodna 24h su izvršene nad *Content* ili Trending objavama i

→ korisnik postaje *Spammer*

Korisnikova „najsvežija“ labela *Spammer* je starija od mesec dana

→ korisnik gubi labelu *Spammer*

PRAVILA ZA PRIMENU KAZNI KORISNIKA

Korisnik je *Spammer* i

korisnik nije prethodno trajno suspendovan

→ korisnik je suspendovan 2 dana

Korisnik je 5 puta dobio *Spammer* labelu i

korisnik nije prethodno trajno suspendovan

→ korisnik je trajno suspendovan

Korisnik je napravio 5 ili više *Harmful* objava i

korisnik nije prethodno trajno suspendovan

→ korisnik je trajno suspendovan

Korisnik je *Harmful User* i

korisnik je dobio labelu *Spammer* nakon labele *Harmful User* i

korisnik nije prethodno trajno suspendovan

→ korisnik je trajno suspendovan

Primeri rezonovanja

Korisnik je objavio štetnu objavu (*forward chaining example*)

Korisnik objavljuje štetnu objavu koja potom biva viđena od strane drugih korisnika. Objava dobija preko 10 prijava nakon čega se kao potencijalno štetna analizira. *Third-party* analiza objave zaključila je da jeste u pitanju štetna objava, i time ažurirala podatak o istoj. Korisnik (ukoliko je ovo prvi put) dobija oznaku *Harmful user*. Korisnik gubi bilo koje druge pozitivne labele koje je možda u međuvremenu stekao.

Korisnik je rapidno prijavljivao sve objave (CEP example)

Korisnik, u ovom slučaju spamer, je rapidno prijavljivao sve objave prikazane na korisničkoj tabli. Napravio je preko 30 aktivnosti u poslednja 24h i polovina ili više su bile negativne interakcije. Korisnik postaje potencijalni spamer. Analizom sadržaja koji je korisnik prijavio utvrđuje se da 80% ili više prijavljenih objava nije zaista bilo lošeg sadržaja (po procenama drugih korisnika). Korisnik postaje spamer, gubi druge pozitivne labela, dobija suspenziju.

Određivanje uslova za *Trending* objavu (accumulate example)

Accumulate neće vršiti masovne transformacije ali hoće računati potreban uslov po broju pozitivnih interakcija kako bi novopristigla objava dobila status *Trending*.

Određivanje uslova za *Trending* objavu 2 (globals example)

Računanje gorepomenutog praga moglo bi da se svede na računanje istog svakih sat vremena, a ne prilikom svake interakcije korisnika. Tada se novodostignuti broj pozitivnih interakcija samo poredi sa prethodno izračunatom vrednosti, čime ne gubimo previše na tačnosti ali dobijamo na performansama sistema.

Suspenzija korisnika (međusobno isključivanje pravila)

Ukoliko se pravilo kojim korisnik dobija trajnu suspenziju izvrši, nema potrebe izvršavati bilo koje drugo pravilo iz ove kategorije.